



Kodiranje medijskih signala

Prof.dr.sc. Davor Petrinović,

20.veljače 2008.




Kodiranje medijskih signala

- Manipulacija sa digitaliziranim medijskim signalima u formatu nominalne točnosti nije pogodna.
- Takav format je previše rastrošan:
 - traži veliki podatkovni tok, dok je
 - stvarna količina informacije sadržana u signalu nekoliko puta manja, a ponekad čak i nekoliko redova veličine puta manja!
- Potrebno je osmisliti postupak kojim je moguće **odvojiti bitno od nebitnog**.



Kodiranje medijskih signala

- Općenito, ... kodiranje (engl. ***coding***) se definira kao predstavljanje informacije nizom bita.
- Kompresija ili sažimanje (engl. ***data compression***) je:
 - kodiranje kojem je cilj smanjiti broj bita kojim se prikazuje određena informacija.





Kodiranje medijskih signala

- Često se termin kodiranja koristi kao sinonim za postupke kompresije, što će biti slučaj i u našim materijalima.
- Kompresija se još naziva postupkom uklanjanja zalihosti, engl. ***redundancy removal***.
- Zadatak kompresije je:
 - format nominalne točnosti transformirati u “ekvivalentu” digitalnu reprezentaciju u kojoj je smanjena ili uklonjena zalihost informacije.



Kodiranje medijskih signala

- Kodiranje u širem smislu se može podijeliti u tri podvrste:
 - kodiranje izvora (engl. **source coding**),
 - entropijsko kodiranje (engl. **entropy coding**) i
 - kodiranje kanala (engl. **channel coding**).
- Prva dva se koriste u kontekstu kompresije, dok se, ...
 - kod kodiranja kanala zapravo **povećava** broj bita poruke u svrhu zaštite informacije prilikom prijenosa.



Kodiranje medijskih signala

- U okviru predmeta MT, baviti ćemo se prvenstveno sa kodiranjem izvora i entropijskim kodiranjem.
- Kodiranje dijelimo i na:
 - kodiranje bez gubitaka (engl. ***Lossless coding***),
 - kodiranje s gubitcima (engl. ***Lossy coding***).
- Savršena rekonstrukcija signala u formatu nominalne točnosti moguća je samo u slučaju kodiranja bez gubitaka!



Kodiranje medijskih signala

- Koja je razlika između kodiranja izvora i entropijskog kodiranja?
 - kodiranje izvora je temeljeno na svojstvima signala na koji se primjenjuje i iskorištava zalihosti koje su vezane uz strukturu konkretnog signala, dok ...
 - entropijsko kodiranje “napada” digitalnu poruku bez poznavanja njenog pravog izvora i ostvaruje kompresiju na račun statističkih svojstava tog digitalnog niza uzoraka.



Informacija i entropija

prof.dr.sc. Davor Petrinović

Priprema materijala:

Ivan Dokmanić, dipl.ing.



Informacija

- Informaciju (količinu informacije) možemo definirati kao **razinu iznenađenja zbog nekog događaja**, odnosno kao nevjerojatnost tog događaja.
- Primjer – pogađanje ženskog imena:
 - Ako nam netko kaže kako je prvo slovo imena *M* (često, vjerojatno prvo slovo), to nam ne znači mnogo, ali ako nam kaže da ime počinje sa *Ž*, količina informacije je mnogo veća i lakše ćemo pogoditi o kojem se imenu radi.



Mjera informacije

- Pretpostavimo bezmemorijski izvor informacija koji može generirati diskretne simbole iz skupa: $S = \{s_1, s_2, s_3, \dots, s_n\}$
- Ako je vjerojatnost generiranja i -tog simbola p_i , količina informacije zbog opažanja tog i -tog simbola je:

$$\log_2 \frac{1}{p_i}$$
- Uzimanje logaritma po bazi 2 daje rezultat u bitovima – (minimalan) broj bitova potreban za reprezentaciju simbola s_i



Entropija

- Entropija nekog izvora informacije je **mjera količine informacije** koju taj izvor generira.
- Ona odgovara prosječnoj (očekivanoj) količini informacije po generiranom simbolu:

$$H(S) = \sum_{i=1}^n p_i \log \frac{1}{p_i}$$

$$H(S) = - \sum_{i=1}^n p_i \log p_i$$



Entropija

- Prethodno definirana entropija odgovara najmanjoj mogućoj prosječnoj dužini kodirane poruke u bitovima.
- Pri tome pretpostavljamo da je izvor bezmemorijski, tj. da vjerojatnost pojave trenutnog simbola niti na koji način nije vezana sa pojavom bilo kojeg drugog simbola prije razmatranog.




Kodovi promjenjive duljine

- Ako su vjerojatnosti pojave pojedinih simbola različite, dobra je ideja onima vjerojatnijima (koji se češće pojavljuju) pridijeliti kraće kodne riječi i tako smanjiti očekivanu dužinu kodirane poruke.
- Kako su kodne riječi različitih dužina, **niti jedna ne smije biti početak neke druge**, radi ostvarenja mogućnosti jedinstvenog dekodiranja.
- Kodovi koji imaju to svojstvo zovu se **prefiksni kodovi**.



Huffmanovi kodovi



- David A. Huffman (1925-1999)



Huffmanovi kodovi

- Zadovoljavaju uvjet prefiksa!
- Algoritam za formiranje Huffmanovog koda:
 1. Sortiraj simbole prema vjerojatnosti,
 2. Odaberi 2 simbola najmanje vjerojatnosti, napravi Huffmanovo pod-stablo čija su djeca ti simboli,
 3. Roditelju dodijeli vjerojatnost koja je zbroj vjerojatnosti djece i ubaci ga u listu simbola tako da je ona i dalje sortirana, a djecu izbaci iz liste
 4. Ponavljaj od 2 dok ne iskoristiš sve simbole,
 5. Dodijeli kodne riječi svakom listu ovog stabla (one odgovaraju putovima od korijena stabla ka listu).




Huffman – primjer

- Uzmimo izvor čiji je alfabet $S = \{A, B, C, D\}$
- Konstruirajmo Huffmanov kod za taj izvor, ako su vjerojatnosti pojedinih simbola kao u tablici

<i>A</i>	<i>B</i>	<i>C</i>	<i>D</i>
0.125	0.5	0.25	0.125



Huffman – primjer



Kodne riječi čitamo od korijena stabla prema listovima

<i>A</i>	<i>B</i>	<i>C</i>	<i>D</i>
000	1	01	001



Huffman – primjer

- Prosječna dužina kodne riječi:
 $0.125 \cdot 3 + 0.125 \cdot 3 + 0.25 \cdot 2 + 0.5 \cdot 1 = 1.75$ bita
- Ta dužina **točno odgovara** entropiji izvora!
- Kodirana poruka **BADBBCBC** je: **10000011101101** i dužine je 14 bita. Da smo koristili jednaku dužinu kodne riječi za sve simbole (2 bita), trebali bismo ukupno 16 bita.
- Da vjerojatnost svakog simbola nije bila cjelobrojna potencija od 0.5 (odnosno da količina informacije po simbolu nije bila cjelobrojna), prosječna dužina kodne riječi bila bi **do najviše za 1 bit veća od entropije!**



Huffman - problem

- Za prirodne procese, količina informacije po simbolu uistinu ne mora biti cjelobrojna, a ova metoda svakom simbolu nužno dodjeljuje cijeli broj bita.
- Ekstreman slučaj je kada je vjerojatnost nekog simbola vrlo velika (>0.5), npr. 0.9
- Količina informacije tog simbola je 0.152 bita, ali će njegova kodna riječ biti dužine 1 bit i prosječna dužina koda značajno veća od entropije.



Aritmetičko kodiranje

- Kako ostvariti frakcionalnu dužinu koda ?
- Ideja: cijelu poruku kodirati odjednom – tj. cijelu poruku kodirati jednim “dugačkim” brojem.



- Jorma J. Rissanen
- smislio postupak dok je radio za IBM ...



Aritmetičko kodiranje

- Neka je $S = \{A, B, C, D, E, F, \$\}$, s vjerojatnostima kao u tablici
- Svakom simbolu dodijelimo podinterval od $[0,1)$, čija širina odgovara vjerojatnosti simbola:
 - česti simboli – širok interval,
 - rijetki simboli – uzak interval.
- Redoslijed intervala je proizvoljan

A	B	C	D	E	F	\$
0.2	0.1	0.2	0.05	0.3	0.05	0.1
$[0, 0.2)$	$[0.2, 0.3)$	$[0.3, 0.5)$	$[0.5, 0.55)$	$[0.55, 0.85)$	$[0.85, 0.9)$	$[0.9, 1)$



Aritmetičko kodiranje

- Kada kodiramo prvi simbol, koncentriramo se samo na podinterval koji odgovara tom simbolu, i njega podijelimo jednako kao što smo podijelili $[0,1)$, tako da narednim simbolima odgovaraju podintervali unutar njega, a širine podintervala su opet proporcionalne vjerojatnostima simbola.
- Kad kodiramo sljedeći simbol, istu stvar napravimo sa podintervalom koji odgovara tom simbolu (a nalazi se unutar intervala koji odgovara prethodnom simbolu).
- Postupak rekurzivno ponavljamo do kraja poruke, a kodirana poruka je bilo koji broj iz završnog intervala




Aritmetičko kodiranje - primjer

- Neka je poruka koju kodiramo CAEE\$
- Postupak je ilustriran sljedećom tablicom u kojoj je za svaki simbol poruke naveden interval koji promatramo:

Simbol	Gornja	Donja	Širina
	0	1	1
C	0.3	0.5	0.2
A	0.3	0.34	0.04
E	0.322	0.334	0.012
E	0.3286	0.3322	0.0036
\$	0.33184	0.3322	0.00036



Aritmetičko kodiranje – primjer





Aritmetičko kodiranje – primjer

- Na kraju je potrebno odabrati najkraću moguću kodnu riječ, odnosno broj iz završnog intervala sa najmanje znamenaka.
- Kada bi podatke predstavljali dekadskim, a ne binarnim znamenkama, taj bi broj očigledno bio 0.332, no u bazi 2 taj broj ima beskonačno mnogo znamenaka.
- Kako u binarnom brojevnom sustavu imamo tek 2 mogućnosti za svaku znamenku, jednostavno je konstruirati algoritam koji će generirati binarni broj s najmanje znamenaka u nekom intervalu.



Aritmetičko kodiranje

1. Postavi b na nulu, a brojač i na 1
2. Dokle god je b manji od donje granice intervala
 1. Postavi i -tu binarnu frakcijsku znamenku od b na 1
 2. Ako je b veći od gornje granice intervala, vrati i -tu znamenku na nulu,
 3. Uvećaj brojač i za 1
3. Uvjet završetka petlje biti će objašnjen kasnije!
 - Završni frakcionalni broj b odgovara traženom broju, i predstavlja kod originalne poruke.
 - U našem primjeru se radi o broju **0.33203125**
 - odnosno u binarnom prikazu **.01010101**



Aritmetičko kodiranje – zašto radi

- Širina završnog intervala odgovara upravo produktu vjerojatnosti svih odaslanih simbola.
- Ako simbole smatramo nezavisnima, tada je taj produkt baš vjerojatnost cijele poruke, p_m .
- Općenito, ako želimo prikazati brojeve iz jako uskih intervala unutar $[0, 1)$, morat ćemo trošiti mnogo znamenaka, jer uski intervali odgovaraju malim vjerojatnostima p_m .



Aritmetičko kodiranje – zašto radi

- U bilo kojem intervalu širine p_m unutar $[0,1)$ postoji realni broj koji se može prikazati binarnom frakcijom čiji je broj binarnih znamenaka najmanji cijeli broj veći od $\log_2(1/p_m)$.
- Veličina $\log_2(1/p_m)$ je upravo količina informacije u cijeloj poruci, što znači da smo poruku kodirali najmanjim mogućim brojem bita, tj. sa najviše do jednog bita viška za cijelu poruku!
- Kod Huffmana svaki simbol kodiramo sa do bitom viška!



Aritmetičko kodiranje – zašto radi

- Za naš primjer, vjerojatnost poruke CAEE\$ je:
 - $p_m = p_C p_A p_E p_E p_\$ = 0.2 \cdot 0.2 \cdot 0.3 \cdot 0.3 \cdot 0.1 =$
 - $p_m = 0.00036$
- Minimalni broj bita za cijelu poruku bio bi jednak entropiji:
 - $-\log_2(p_m) = 11.44$ bit
- U realnom sustavu koristimo 12 bita i šaljemo poruku:
 - **.010101010000**
- Dakle, broj prolaza petlje za traženje frakcije je 12



Aritmetičko kodiranje

- Proces dekodiranja je jednostavan i svodi se na čitanje slike sa podjelom pod-intervalu unazad:
 - Pogledamo unutar kojeg intervala se nalazi trenutni broj (kodna riječ);
 - trenutni dekodirani simbol odgovara tom intervalu.
 - Sljedeći je korak oduzimanje donje granice identificiranog intervala od trenutne vrijednosti broja i skaliranje na jedinični interval dijeljenjem sa širinom intervala (tj. vjerojatnosti) dekodiranog simbola.
 - Tako modificirani broj vraćamo u prvi korak algoritma i ponavljamo postupak.



Aritmetičko kodiranje

- Ilustracija dekodiranja poruke, opisane 12-bitnom frakcijom $b = .010101010000$

Trenutna vrijednost	Izlazni simbol	Donja granica	Gornja granica	Širina intervala
0.33203125	C	0.3	0.5	0.2
0.16015625	A	0	0.2	0.2
0.80078125	E	0.55	0.85	0.3
0.8359375	E	0.55	0.85	0.3
0.953125	\$	0.9	1	0.1



Aritmetičko kodiranje

- Potencijalni problem nastaje zbog činjenice da se proces dekodiranja može nastaviti do beskonačnosti.
- To se rješava uvođenjem simbola koji simbolizira kraj poruke (\$ u primjeru).
- Uvođenjem tog simbola narušava se optimalnost, ali bez obzira na to ovaj je postupak u većini slučajeva superioran Huffmanovom kodiranju.
- Jedan od razloga slabije primjene ovog algoritma je zbog činjenice da je zaštićen većim brojem patenata!



Aritmetičko kodiranje – problem

- Da je naša idealna kodirana poruka pogreškom izmijenjena i to tako da smo samo zadnji bit poruke podigli u 1
 - **.010101010001** (0.332275390625)
- ... to bi imalo kobnu posljedicu na dekodiranje, jer je ona izvan završnog intervala kodiranja $[0.33184, 0.3322)$ i dekodira se kao:
 - CAE**FAEBEA**\$ te odgovara 26-bitnoj frakciji:
 - **.0101010100010000000000000000**



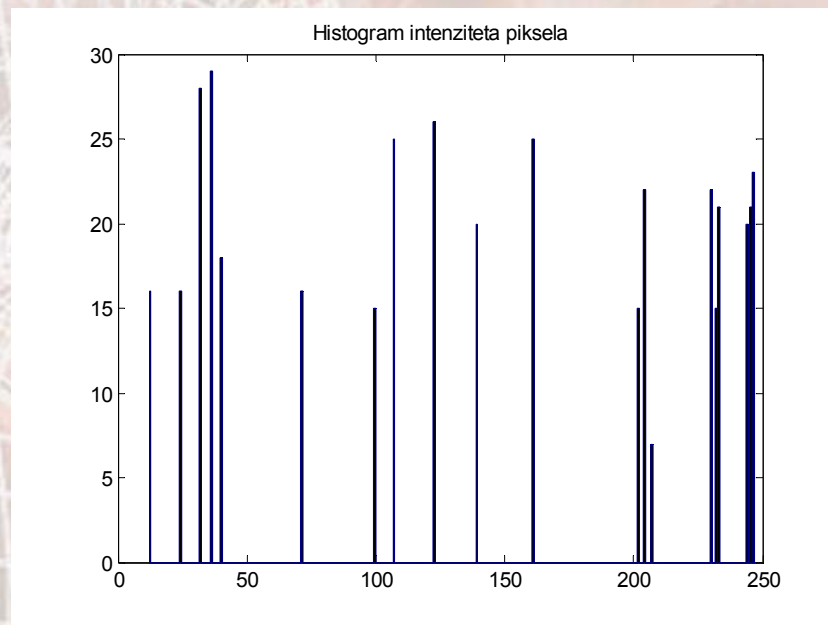
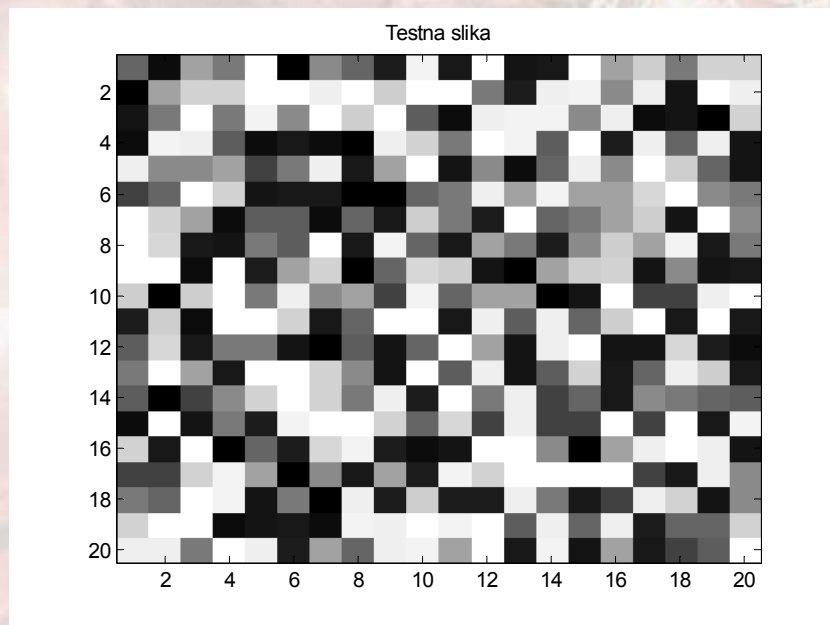
Aritmetičko kodiranje – problem

- Pogrešno dekodirana poruka:

Trenutna vrijednost	Izlazni simbol	Donja granica	Gornja granica	Širina intervala
0.332275390625	C	0.3	0.5	0.2
0.161376953125	A	0	0.2	0.2
0.806884765625	E	0.55	0.85	0.3
0.85628255208333	F	0.85	0.9	0.05
0.12565104166668	A	0	0.2	0.2
0.62825520833339	E	0.55	0.85	0.3
0.26085069444465	B	0.2	0.3	0.1
0.60850694444649	E	0.55	0.85	0.3
0.19502314815497	A	0	0.2	0.2
0.97511574077485	\$	0.9	1	0.1



Primjer primjene entropijskog koda na sliku



Entropije slike je 4.2688 bita po pixelu, dakle minimalan broj bita za cijelu sliku je $20 \cdot 20 \cdot 4.2688 = 1707.5$, za razliku od $20 \cdot 20 \cdot 8 = 3200$ bez kompresije.



Zaključak

- Huffmanov koder i aritmetički koder su oba entropijski koderi:
 - sažimanje ostvaruju primjenom koda varijabilne dužine u skladu sa statistikom signala;
 - time se skraćuje prosječna dužina koda i izlazni podatkovni tok kodirane poruke približava teorijskom minimumu definiranom entropijom;
 - dodatna prednost aritmetičkog koda je uslijed frakcionalne dužine koda pojedinog simbola.



Što smo naučili

- definicija kodiranja i kompresije
- tipovi kodiranja i podjele
- informacija
- mjera informacije, entropija
- entropijski koderi
- kodovi promjenjive duljine
- Huffmanovi kodovi
- aritmetički koder



Entropija i kvaliteta

prof.dr.sc. Davor Petrinović



Kodiranje izvora radi kompresije

- Problem:
 - Imamo amplitudno kontinuirani vremenski diskretni proces, kojeg želimo kodirati u svrhu kompresije;
 - amplitudno kontinuirani proces pretvaramo u diskretni digitalizacijom (kvantizacijom);
 - želimo primijeniti entropijski koder na izlazu kvantizatora, radi kompresije.
 - Koji je odnos kvalitete (pogreške kvantizacije) i entropije izlazne kodirane poruke ?



Kodiranje izvora radi kompresije

- **Kodiranje s ograničenom entropijom**
 - Kanal ima konačni raspoloživi podatkovni tok kroz koji se šalje kodirana informacija.
 - Kako projektirati kvantizator da nakon entropijskog kodiranja poruka “stane” u kanal, a da se pri tome ostvari čim veća kvaliteta?
- **Kodiranje s ograničenom distorzijom**
 - Rekonstruirani signal mora imati pogrešku kvantizacije manju od propisane.
 - Kako projektirati kvantizator koji minimizira potrebnu širinu kanala (podatkovni tok) kojim se to ostvaruje, te koliko iznosi potrebni tok?



Kodiranje izvora radi kompresije

- Odgovor na ova pitanja daje teorija informacije (engl. **Information Theory, IT**), a posebice njena grana koja se odnosi na kodiranje izvora (engl. **Source coding**).
- Dio IT-a je teorija koja se bavi izučavanjem odnosa kvalitete i podatkovnog toka i naziva se engl. **Rate-Distortion theory**.
- Temeljni radovi u ovom području ... Claude Shannon, 1948.-, za vrijeme rada u Bell laboratoriju.



Kodiranje izvora radi kompresije

- Svi moderni koderi medijskih signala intenzivno koriste znanja iz Teorije informacija.
- Ilustrirati ćemo primjenu TI-a na primjeru skalarne kvantizacije s ograničenom entropijom (engl. ***Entropy Constrained Scalar Quantization, ECSQ***).
- ECSQ ima niz praktičnih primjena u kodiranju, a posebice u kodiranju audio signala.
 - ima veliku učinkovitost kod kodiranja dužih nizova statistički nezavisnih (ili barem nekoreliranih) uzoraka.



Skalarna kvantizacija ograničene entropije, ECSQ

- ECSQ kvantizacija se tipično primjenjuje na:
 - uzorke signala u originalnoj vremenskoj ili prostornoj domeni,
 - na koeficijente transformacije signala u nekoj od domena transformacija,
 - na uzorke potpojasnih signala kod struktura koje koriste filtarske slogove za spektralno razlaganje signala,
 - na uzorke signala predikcijske pogreške kod koda koji koriste prediktore u svrhu vremenske ili prostorne dekorelacije,
 - na parametre modela, kod koda temeljenih na modelu sa velikim brojem parametara.



Skalarna kvantizacija ograničene entropije, ECSQ

- Ulaz u postupak kodiranja je digitalizirani medijski signal nominalne točnosti;
 - Iako je ovaj signal već amplitudno diskretiziran ulaznim A/D pretvornikom, on se tretira kao “beskonačno” točan, jer je
 - ulazna rezolucija u pravilu mnogo veća od rezolucije ECSQ kvantizatora koji se koristi u sklopu koda u svrhu kompresije.
 - Obično se koristi bipolarna frakcionalna interpretacija ulaznog signala (+/-1), dijeljenjem cjelobrojne vrijednosti sa 2^{b-1}




Uniformna skalarna kvantizacija- primjer

- Primjer:
 - Proces u frakcionalnom zapisu ± 1 kvantiziramo uniformnim kvantizatorom sa $N=5$ kvantizacijskih razina, tj. sa korakom $\Delta=2/N=0.4$
 - kvantizacijski razredi su $C_i=[\Delta \cdot i - \Delta/2, \Delta \cdot i + \Delta/2)$
 - $C_{-2}=[-1.0, -0.6)$ kod **-2** (centroid $x_{q-2} = -0.8$)
 - $C_{-1}=[-0.6, -0.2)$ kod **-1** (centroid $x_{q-1} = -0.4$)
 - $C_0=[-0.2, +0.2)$ kod **0** (centroid $x_{q0} = 0$)
 - $C_1=[+0.2, +0.6)$ kod **1** (centroid $x_{q1} = 0.4$)
 - $C_2=[+0.6, +1.0]$ kod **2** (centroid $x_{q2} = 0.8$)
 - Rekonstrukciju provodimo **zamjenom koda i sa pripadnim centroidom i -tog razreda $x_{qi}=\Delta \cdot i$**




Uniformna skalarna kvantizacija- primjer

- ... nastavak:
 - uniformni raspored kvantizacijskih razreda C_i preko područja vrijednosti ulaznog procesa X :





Uniformna skalarna kvantizacija- primjer





Uniformna skalarna kvantizacija- primjer

- Izlazni proces kvantizacijskih kodova $I=\{i\}$ ima pet simbola $i \in \{-2, -1, 0, 1, 2\}$
- Kolika je entropija ovog diskretnog izvora I ?
- ... određena je vjerojatnostima pojedinih simbola:

$$H(I) = - \left(p_I(-2) \log p_I(-2) + p_I(-1) \log p_I(-1) + \right. \\ \left. + p_I(0) \log p_I(0) + p_I(1) \log p_I(1) + p_I(2) \log p_I(2) \right)$$

- vjerojatnosti simbola $p_I(i)$ mogu se odrediti integriranjem *pdf* funkcije procesa $f_X(x)$ unutar i -tog razreda:

$$p_I(i) = \int_{x \in C_i} f_X(x) dx = \int_{\Delta i - \Delta/2}^{\Delta i + \Delta/2} f_X(x) dx$$



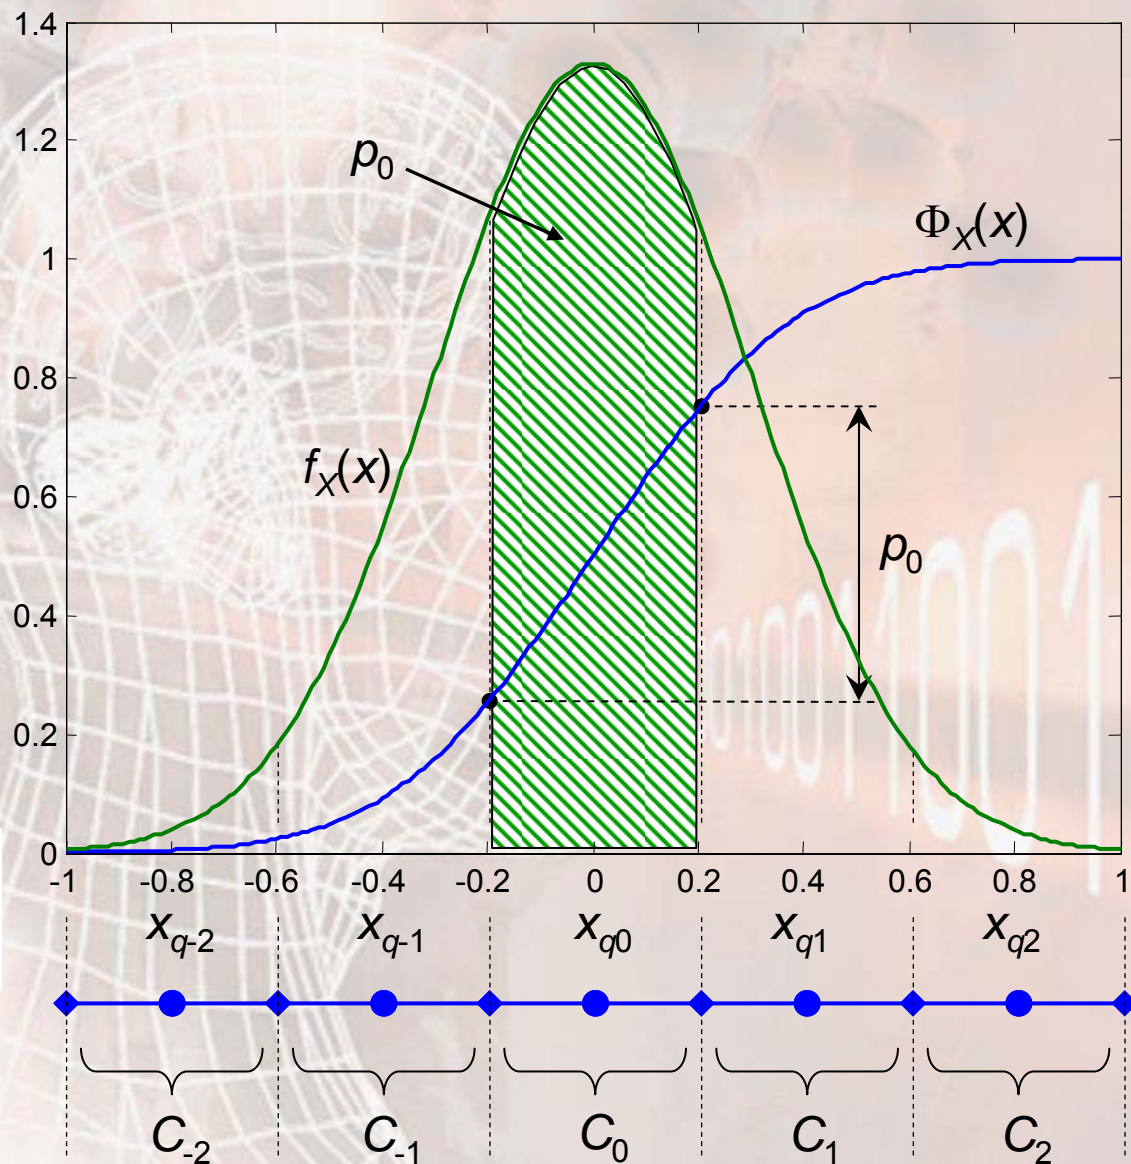
- npr. vjerojatnost simbola $i=0$ je:

$$p_I(0) = \int_{-\Delta/2}^{+\Delta/2} f_X(x) dx$$

- ili diferenciranjem *cdf*-a procesa na rubovima razreda:

$$p_I(0) = \Phi_X\left(\frac{\Delta}{2}\right) - \Phi_X\left(-\frac{\Delta}{2}\right)$$

$$\Phi_X(x) = \int f_X(x) dx$$





Uniformna skalarna kvantizacija- primjer

- ... nastavak:
 - Entropija $H(I)$ je najveća kada su svi izlazni simboli jednako vjerojatni $p_I(i)=1/N$, za $i=-2, -1, 0, 1$ i 2 ;
 - To je slučaj kada proces ima uniformnu gustoću:

$$f_X(x) = \frac{1}{\Delta N} \quad p_I(i) = \frac{1}{\Delta N} \int_{\Delta i - \Delta/2}^{\Delta i + \Delta/2} dx = \frac{1}{\Delta N} \Delta = \frac{1}{N}$$

- Dobiva se: $\max(H(I))=\log(N)=2.32$ bita
- Napomena: ako koristimo prirodni logaritam u izrazu za entropiju, $H(I)$ se izražava u **natima**, a ako koristimo logaritam baze 2, tada je u **bitovima**!



Uniformna skalarna kvantizacija- primjer

- ... nastavak:

- Kolika je distorzija D uslijed kvantizacije?

$$D = E[(x - x_q)^2] = \int_x f_X(x) \cdot (x - x_q)^2 dx \quad x_q = \Delta \cdot \text{round}(x / \Delta)$$

- Kvantizirani signal x_q je iz konačnog skupa centroida:

$$\begin{aligned} x_q \in \{x_{q_i}\} &= \{x_{q-2}, x_{q-1}, x_{q0}, x_{q1}, x_{q2}\} \\ &= \{-2\Delta, -\Delta, 0, \Delta, 2\Delta\} \end{aligned}$$

- pa je distorziju D je pogodnije prikazati kao sumu ukupne distorzije unutar pojedinih kvantizacijskih razreda D_i

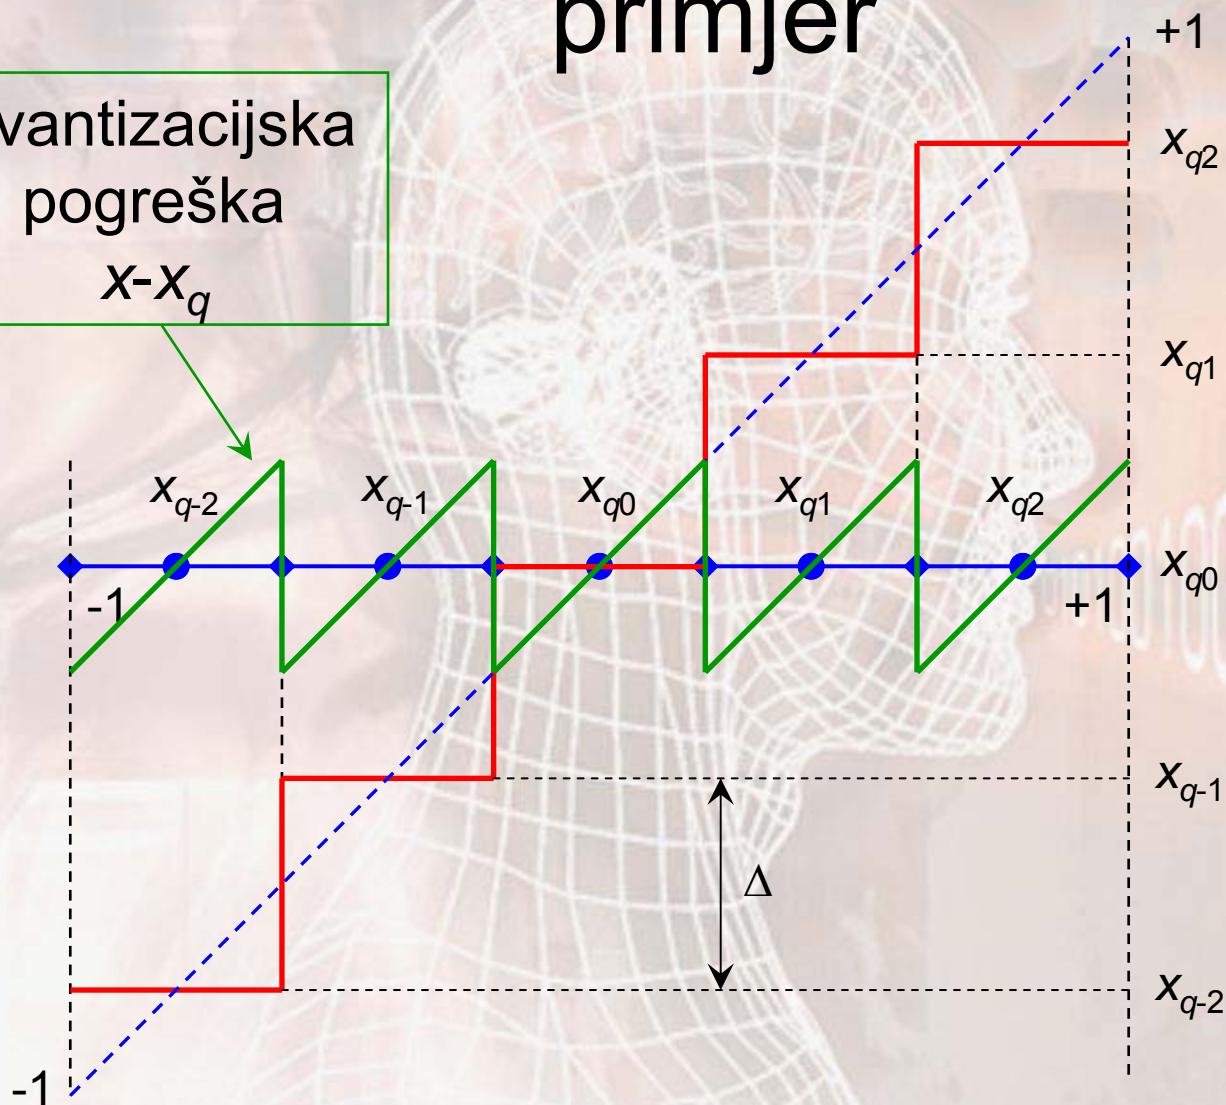
$$D = \sum_i D_i = \sum_i \int_{x \in C_i} f_X(x) \cdot (x - x_{q_i})^2 dx$$



Uniformna skalarna kvantizacija- primjer

Kvantizacijska
pogreška

$$x - x_q$$





Uniformna skalarna kvantizacija-primjer

- ... nastavak:
 - Ako je signal uniformne gustoće vjerojatnosti $f_X(x)=1/(\Delta N)$, distorziju možemo lako odrediti:

$$D = \sum_i \frac{1}{\Delta N} \int_{\Delta i - \Delta/2}^{\Delta i + \Delta/2} (x - \Delta i)^2 dx = \sum_i \frac{1}{\Delta N} \int_{-\Delta/2}^{+\Delta/2} x'^2 dx' = \sum_i \frac{\Delta^2}{12N} = \frac{\Delta^2}{12}$$

- dok varijancu ulaznog procesa nalazimo kao:

$$\sigma_x^2 = E[(x - E[x])^2] = E[x^2] = \int_x f_X(x) x^2 dx$$

$$\sigma_x^2 = \frac{1}{\Delta N} \int_{-\Delta N/2}^{\Delta N/2} x^2 dx = \frac{(\Delta N)^2}{12}$$



Uniformna skalarna kvantizacija- primjer

- Konačno dobivamo $SQNR$ odnos za proces uniformne gustoće vjerojatnosti $f_X(x)=1/(\Delta N)$ kvantiziran uniformnim kvantizatorom sa N razina koje potpuno pokrivaju područje vrijednosti procesa X :

$$SQNR(N) = 10\log_{10} \frac{\sigma_x^2}{D} = 20\log_{10}(N) \quad [dB]$$

- uz entropiju izlaznih simbola $H(I)$:

$$H(I) = \log_2(N) \quad [bit]$$

- što daje slijedeću jednostavnu vezu:

$$SQNR(N) = (20\log_{10} 2)H(I) = 6.02H(I) \quad [dB]$$



Uniformna skalarna kvantizacija- primjer

- Diskusija:
 - entropija izražena u bitovima i distorzija uslijed kvantizacije izražena u dB su linearno vezane;
 - za smanjenje distorzije od 6dB potrebno je izlaznu entropiju povećati za 1 bit;
 - zbog uniformne razdiobe ulaznog procesa, entropijski koder ne ostvaruje sažimanje varijabilnom dužinom koda, jer su kodovi svih simbola iste dužine;
 - izlazna entropija bilo kojeg drugog ulaznog procesa mora biti manja;
 - distorzija za proizvoljni $f_X(x)$ mora se odrediti zbrajanjem očekivane pogreške D_i koja se nalazi integracijom unutar svakog kvantizacijskog razreda.



Što smo naučili

- kodiranje s ograničenom entropijom / distorzijom
- teorija informacija, grane i primjene
- skalarna kvantizacija s ograničenom entropijom i primjene
- uniformna skalarna kvantizacija – primjer
- odnos kvalitete i entropije



Teorija kvantizacije visokog podatkovnog toka (kvalitete)

prof.dr.sc. Davor Petrinović



Skalarna kvantizacija ograničene entropije, ECSQ

- Problem ...
 - što ako *pdf* funkcija procesa nije uniformna;
 - što ako proces nema ograničeno područje vrijednosti;
 - da li je uopće uniformni raspored centroida kvantizatora i pripadnih razreda najbolje rješenje za proizvoljni *pdf* procesa?
 - kako moraju biti raspoređeni centroidi da minimiziraju pogrešku D za zadanu entropiju $H(I)$, ili obrnuto da minimiziraju entropiju za zadanu distorziju D ?



Skalarna kvantizacija ograničene entropije, ECSQ

- Analitičko rješenje nažalost ne postoji za općenit slučaj,
- ... ali se primjenom *teorije kvantizacije visokog podatkovnog toka* (engl. ***High Rate Quantization Theory, HR***) može odrediti asimptotsko rješenje za visoke rezolucije (odnosno visoku kvalitetu rekonstrukcije).
- Pokazuje se da je ovo rješenje upotrebljivo za ocjenu ponašanja koda čak i za vrlo male rezolucije!



HR-ECSQ

- Ključna ideja HR teorije je slijedeća:
 - ako su kvantizacijski razredi dovoljno uski, tada se prilikom integracije unutar jednog razreda može pretpostaviti da je funkcija gustoće vjerojatnosti približno konstantna i da se može aproksimirati s vrijednosti *pdf* funkcije u točki centroida tog razreda:

$$f_X(x) \big|_{x \in C_i} \cong f_X(x_{q_i})$$

- Ovo značajno olakšava izračunavanje integrala u izrazima za entropiju i distorziju.



HR-ECSQ

- Uz opisanu pretpostavku na visok podatkovni tok dobivamo slijedeće rješenje:
 - ... uistinu, kvantizator s uniformnim razmakom kvantizacijskih nivoa Δ , je najbolje rješenje **za svaki** ulazni proces!
 - Odnos izlazne entropije $H(I)$ i distorzije D uslijed kvantizacije s korakom Δ je:

$$H(I) = h(X) - \frac{1}{2} \log_2(12D)$$

$$D = \frac{\Delta^2}{12}$$

- ... gdje je $h(X)$ diferencijalna entropija procesa X



Diferencijalna entropija

- Diferencijalna entropija predstavlja poopćenje izraza za entropiju na procese kontinuirane varijable ...
 - izraz je potpuno analogan, samo što je suma zamijenjena s integralom preko područja vrijednosti procesa:

$$h(X) = - \int_x f_X(x) \cdot \log(f_X(x)) dx$$

$$h(X) = E[-\log(f_X(x))]$$



HR-ECSQ

- Izraz za odnos entropije i kvalitete ECSQ kvantizatora se može napisati i u slijedećem obliku:

$$SQNR = (20 \log_{10} 2) H(I) + SQNR_0 \quad [dB]$$

- offset ove linearne veze, $SQNR_0$, ovisi o svojstvima ulaznog procesa, ... njegovoj **varijanci i diferencijalnoj entropiji**:

$$SQNR_0 = (20 \log_{10} 2) \cdot \left(\frac{1}{2} \log_2 (12 \sigma_x^2) - h(X) \right)$$

$$SQNR_0 = 20 \log_{10} (\sqrt{12 \sigma_x^2} 2^{-h(X)})$$



HR-ECSQ

- Promotrimo utjecaj člana $SQNR_0$...
 - veći offset $SQNR_0$, osigurava bolju kvalitetu za istu izlaznu entropiju $H(I)$;
 - za procese s istom varijancom σ_x^2 , manji $h(X)$ implicira veći $SQNR_0$, a time i bolju kvalitetu;
 - Dakle, **diferencijalna entropija $h(X)$ predstavlja mjeru kompleksnosti ulaznog procesa sa stanovišta učinkovitosti kvantizacije i entropijskog kodiranja.**



HR-ECSQ

- Kako odrediti korak ECSQ kvantizatora za zadanu širinu kanala, tj. ograničenu izlaznu entropiju $H(I)$?
 - iz izraza za vezu distorzije i entropije slijedi:
$$\Delta = 2^{h(X) - H(I)}$$
 - Diferencijalnu entropiju $h(X)$ određujemo iz poznate funkcije gustoće vjerojatnosti ulaznog procesa $f_X(x)$.



HR-ECSQ

- Kako odrediti potrebnu izlaznu entropiju $H(I)_{\min}$ i korak ECSQ kvantizatora Δ za zadanu minimalnu kvalitetu $SQNR_{\min}$?
 - Na osnovu $f_X(x)$ računamo $h(X)$ te određujemo offset linearne veze entropije i $SQNR_0$:

$$SQNR_0 = 20 \log_{10} (\sqrt{12} \sigma_x^2 2^{-h(X)})$$

- Entropiju $H(I)_{\min}$ i korak Δ tada nalazimo kao:

$$H(I)_{\min} = \frac{SQNR_{\min} - SQNR_0}{20 \log_{10} 2}$$

$$\Delta = 2^{h(X) - H(I)_{\min}}$$



Diferencijalna entropija – primjer 1

- Odredimo diferencijalnu entropiju za nekoliko tipičnih procesa varijance σ_x^2 .
- Proces uniformne gustoće vjerojatnosti:

$$f_{X_{unif}}(x) = \begin{cases} \frac{1}{\sqrt{12\sigma_x^2}} & \text{za } |x| < \sqrt{3\sigma_x^2} \\ 0 & \text{inace} \end{cases}$$

$$\Phi_{X_{unif}}(x) = \begin{cases} \frac{x + \sqrt{3\sigma_x^2}}{\sqrt{12\sigma_x^2}} & \text{za } |x| < \sqrt{3\sigma_x^2} \\ 0 & \text{inace} \end{cases}$$



Diferencijalna entropija – primjer 1

- Diferencijalna entropija za proces uniformne gustoće vjerojatnosti, nultog očekivanja i zadane varijance σ_x^2 je:

$$h(X_{unif}) = \frac{\log_2(12\sigma_x^2)}{\sqrt{12\sigma_x^2}} \int_{-\sqrt{3\sigma_x^2}}^{\sqrt{3\sigma_x^2}} dx = \log_2 \sqrt{12\sigma_x^2} \text{ [bit]}$$

$$\begin{aligned} SQNR_{0unif} &= 10 \log_{10} (12\sigma_x^2 \cdot 2^{-2h(X_{unif})}) \\ &= 10 \log_{10} (12\sigma_x^2 \cdot 2^{-2 \log_2 \sqrt{12\sigma_x^2}}) = 0 \text{ [dB]} \end{aligned}$$



Diferencijalna entropija – primjer 1

- Očito je da veza kvalitete $SQNR$ i entropije $H(I)$ ima nulti offset $SQNR_{0unif}$, što je jednako rezultatu koji smo već prije izveli u primjeru za slučaj procesa uniformne razdiobe.
- Kvantizacijski korak Δ za zadanu izlaznu entropiju kvantizacijskih indeksa $H(I)$ za proces uniformne razdiobe i varijance σ_x^2 se računa prema slijedećem izrazu:

$$\Delta_{unif} = 2^{h(X_{unif})} \cdot 2^{-H(I)} = \sqrt{12\sigma_x^2} \cdot 2^{-H(I)}$$



Diferencijalna entropija – primjer 2

- Slučajni proces normalne razdiobe s nultim očekivanjem i varijancom σ_x^2 , tzv. Gaussov bijeli šum:

$$f_{X_{norm}}(x) = \frac{1}{\sqrt{2\pi\sigma_x^2}} \cdot e^{-\frac{x^2}{2\sigma_x^2}}$$

$$\Phi_{X_{norm}}(x) = \frac{1}{2} \left(1 + \operatorname{erf} \left(\frac{x}{\sqrt{2\sigma_x^2}} \right) \right)$$

$$\operatorname{erf}(z) = \frac{2}{\sqrt{\pi}} \int_0^z e^{-t^2} dt$$

- gdje je $\operatorname{erf}(\)$ takozvana error funkcija koja je numerički implementirana u Matlabu.



Diferencijalna entropija – primjer 2

- Diferencijalna entropija za slučajni proces normalne razdiobe, nultog očekivanja i varijance σ_x^2 je:

$$h(X_{norm}) = \frac{-1}{\sqrt{2\pi\sigma_x^2}} \int_{-\infty}^{+\infty} e^{-\frac{x^2}{2\sigma_x^2}} \log_2 \left(\frac{1}{\sqrt{2\pi\sigma_x^2}} e^{-\frac{x^2}{2\sigma_x^2}} \right) dx =$$

$$h(X_{norm}) = \frac{-1}{\ln(2)\sqrt{2\pi\sigma_x^2}} \int_{-\infty}^{+\infty} e^{-\frac{x^2}{2\sigma_x^2}} \left(-\frac{1}{2} \ln(2\pi\sigma_x^2) - \frac{x^2}{2\sigma_x^2} \right) dx =$$



Diferencijalna entropija – primjer 2

– nastavak ... :

$$h(X_{norm}) = \frac{\frac{1}{2} \ln(2\pi\sigma_x^2)}{\ln(2)} \cdot \frac{1}{\sqrt{2\pi\sigma_x^2}} \int_{-\infty}^{+\infty} e^{-\frac{x^2}{2\sigma_x^2}} dx + \frac{1}{\ln(2)2\sigma_x^2} \cdot \frac{1}{\sqrt{2\pi\sigma_x^2}} \int_{-\infty}^{+\infty} x^2 e^{-\frac{x^2}{2\sigma_x^2}} dx$$

$$\int_{-\infty}^{+\infty} x^2 e^{-\frac{x^2}{2\sigma_x^2}} dx = \left(-\sigma_x^2 x \cdot e^{-\frac{x^2}{2\sigma_x^2}} + \frac{\sqrt{2\pi\sigma_x^6}}{2} \operatorname{erf}\left(\frac{x}{\sqrt{2\sigma_x^2}}\right) \right) \Bigg|_{-\infty}^{+\infty} =$$

$$= \left(-\sigma_x^2 x \cdot (e^{-\infty} - e^{-\infty}) + \frac{\sqrt{2\pi\sigma_x^6}}{2} (\operatorname{erf}(\infty) - \operatorname{erf}(-\infty)) \right) = \sqrt{2\pi\sigma_x^6}$$



Diferencijalna entropija – primjer 2

– nastavak ... konačno dobivamo $h(X_{norm})$:

$$\begin{aligned} h(X_{norm}) &= \frac{1}{2} \log_2(2\pi\sigma_x^2) + \frac{1}{\ln(2)2\sigma_x^2} \cdot \frac{1}{\sqrt{2\pi\sigma_x^2}} \sqrt{2\pi\sigma_x^6} \\ &= \frac{1}{2} \log_2(2\pi\sigma_x^2) + \frac{1}{2} \log_2(e) = \frac{1}{2} \log_2(2\pi e \sigma_x^2) \text{ [bit]} \end{aligned}$$

$$\begin{aligned} SQNR_{0norm} &= 10 \log_{10}(12\sigma_x^2 \cdot 2^{-2h(X_{norm})}) \\ &= 10 \log_{10}(12\sigma_x^2 \cdot 2^{-\log_2 2\pi e \sigma_x^2}) \\ &= 10 \log_{10}\left(\frac{12\sigma_x^2}{2\pi e \sigma_x^2}\right) = 10 \log_{10}\left(\frac{6}{\pi e}\right) = -1.53 \text{ [dB]} \end{aligned}$$



Diferencijalna entropija – primjer 2

- Nađimo konačno i izraz za kvantizacijski korak Δ za zadanu entropiju $H(I)$ za šum normalne razdiobe i varijance σ_x^2 :

$$\Delta_{norm} = 2^{h(X_{norm})} \cdot 2^{-H(I)} = \sqrt{2\pi e \sigma_x^2} \cdot 2^{-H(I)}$$

- Zaključno, ... proces normalne razdiobe ima 1.53dB veću distorziju od procesa uniformne razdiobe za istu varijancu i istu izlaznu entropiju.
- To je zato što korak kvantizacije Δ_{norm} mora biti za 1.193 puta veći od Δ_{unif} da bi dobili istu entropiju $H(I)$

$$\frac{\Delta_{norm}}{\Delta_{unif}} = \frac{\sqrt{2\pi e \sigma_x^2}}{\sqrt{12\sigma_x^2}} = \sqrt{\frac{\pi e}{6}} = 1.193$$



HR-ECSQ

- Može se teorijski dokazati da je proces normalne gustoće vjerojatnosti najsloženiji za ECSQ kvantizaciju od svih procesa sa istom varijancom!
- To je zato što ima najveću moguću diferencijalnu entropiju $h(X)$.
- Dakle, ... za ulazni proces nepoznate *pdf* funkcije kojem poznajemo samo varijancu σ_x^2 uvijek vrijedi:

$$h(X) \leq h(X_{norm}) = \log_2 \sqrt{2\pi e \sigma_x^2} \text{ [bit]}$$

- ... što nam može poslužiti kao gornja ograda prilikom projektiranja kvantizatora.



HR-ECSQ

- U okviru primjera 2 pokazali smo:
 - da se skalarni kvantizator sa ograničenom izlaznom entropijom može projektirati i teorijski analizirati čak i za procese sa beskonačnim područjem vrijednosti, što je slučaj za Gaussov proces;
 - u praksi se, zbog projektiranja entropijskog koda, skup izlaznih simbola ipak ograničava.



Generiranje procesa u Matlabu

- Generator realizacija tri procesa jedinične varijance i nulte srednje vrijednosti:

```
n=[0:N-1];      % vremenska os

w=pi*(0.1+0.8*rand); % slučajna frekvencija za sinus i
                    % trokut ... od 0.1*pi do 0.9*pi
if (sig==1),       % sinusni signal
    y=sin(w*n);    % vrem. diskretni signal
elseif (sig==2),   % slučajni sum normalne razdiobe
    y=randn(1,N);  % generiraj sum
elseif (sig==3),   % pilasti napon
    fa=w*n;        % trenutna faza
    fa=fa-2*pi*floor(fa/2/pi); % osnovna vrijednost faze
    y=fa/pi-1;     % pila od -1 do 1
end;

y=y-mean(y);      % ukloni srednju vrijednost
y=y/sqrt(var(y)); % normaliziraj varijancu na 1
```




Projektiranje ECSQ kvantizatora u Matlabu

- Izračun diferencijalne entropije $h(X)$ i potrebnog kvantizacijskog koraka Δ :

```
% Diferencijalne entropije za nase signale

sigma=1;
if (sig==1),           % za sinus
    hX=1/2*log2(pi^2*sigma^2/2);
elseif (sig==2),       % sum normalne razdiobe
    hX=1/2*log2(2*pi*exp(1)*sigma^2);
elseif (sig==3),       % trokutni signal
    hX=1/2*log2(12*sigma^2);
end;

% Korak kvantizacije za zadanu izlaznu entropiju
% H nalazimo kao:
D=2^(hX-H);
```



Kvantizacija procesa u Matlabu

- Izračun očekivane i stvarne pogreške kvantizacije i sama provedba skalarne kvantizacije:

```
% Ocekivana srednja kvadratna pogreska kvantizacije
% je direktno odredjena sa korakom D
E_er_oc=1/12*D^2;

% Obzirom da su signali jedinicne varijance,
% ocekivani SNR za taj korak kvantizacije je:
SNR_oc(i)=10*log10(1/E_er_oc); % [dB]

% sada provedi stvarnu kvantizaciju realizacije procesa
yi=round(y/D);           % izlazni indeksi kvantizatora
yq=D*yi;                 % kvantizirani signal

er=y-yq;                 % pogreska kvantizatora
E_er=mean(er.^2);        % ocekivanje kvadrata pogreske
E_y=mean(y.^2);          % ocekivanje kvadrata signala

SNR(i)=10*log10(E_y/E_er); % Stvarni odnos signal sum [dB]
```



Izlazna entropija

- Izračun stvarnog *pdf*-a i entropije izlaznih indeksa kvantizirane realizacije procesa korištenjem histograma:

```
% min & max izlazni kod
yi_min=min(yi);  yi_max=max(yi);

% svi kodovi od min do max
kod=[yi_min:yi_max];

% odredi vjerojatnost pojave pojedinog koda u
% ovoj realizaciji slucajnog procesa korištenjem
% histograma
pdf=hist(yi,kod)/N;

% Odredi entropiju realizacije
kod_postoji=find(pdf>0);
HI(i)=-pdf(kod_postoji)*log2(pdf(kod_postoji))';
```




Očekivana izlazna entropija

- Izračun očekivanog *pdf*-a i entropije izlaznih indeksa diferenciranjem analitičkog *cdf*-a ulaznog procesa na rubovima kvantizacijskih razreda:

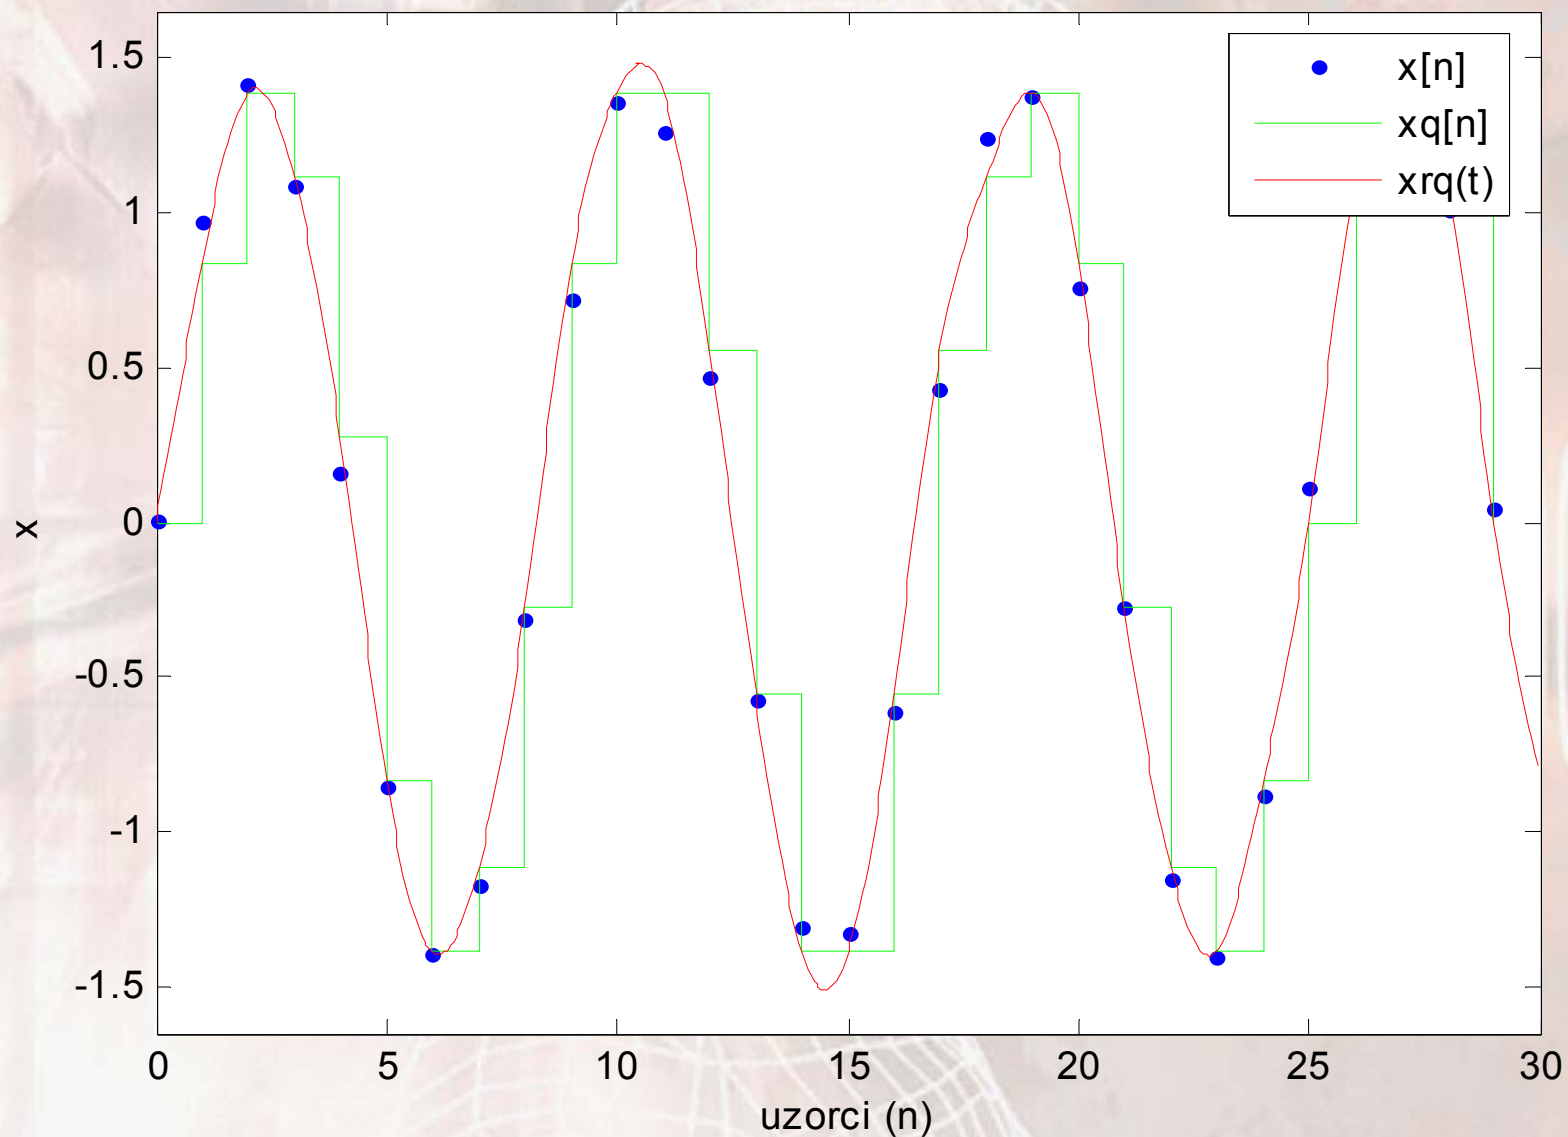
```
delt=max(abs(y));           % tjemeni faktor
% Pragovi kvantizacije u rasponu korištenih kodva
prag=[yi_min-1/2 [yi_min:yi_max]+1/2]*D;

arg=prag/delt;               % argument acos-a i trokuta mora biti
arg=max(min(arg,1),-1);      % unutar +/- 1
% Otipkaj cdf funkciju nasih signala jedinice varijace
if (sig==1),                 % za sinusni signal
    cdf_prag=acos(-arg)/pi;
elseif(sig==2),              % za sum normalne razdiobe
    cdf_prag=1/2*(1+erf(prag/sqrt(2)));
elseif(sig==3),              % za pilasti signal
    cdf_prag=(1+arg)/2;
end;
% očekivana vjerojatnost pojedinog simbola je
% diferencija cdf-a između susjelih pragova
pdf_oc=diff(cdf_prag);
HI_oc(i)=-pdf_oc*log2(pdf_oc)'; % očekivana izlazna entropija
```



Proces 1 – sinusni signal $\sigma_x^2=1$, $H(l)=3$


Uzorci $x[n]$, kvantizirani signal $xq[n]$ i rekonstrukcija $xrq(t)$





Proces 2 – slučajni šum $\sigma_x^2=1$, $H(f)=3$


Uzorci $x[n]$, kvantizirani signal $xq[n]$ i rekonstrukcija $xrq(t)$





Proces 3 – trokutni signal $\sigma_x^2=1$, $H(l)=3$


Uzorci $x[n]$, kvantizirani signal $xq[n]$ i rekonstrukcija $xrq(t)$





1. Sinus –pdf izlaznih simbola $H(I)=4$


PDF kvantiziranog signala






2. Gauss šum –pdf izlaznih simbola $H(1)=4$

PDF kvantiziranog signala






3. Trokut –pdf izlaznih simbola $H(I)=4$





1. Sinus – R-D krivulje $H(I)=1..16$


Stvarni i očekivani SQNR za stvarnu i očekivanu entropiju





2. Gauss šum – R-D krivulje $H(I)=1..16$

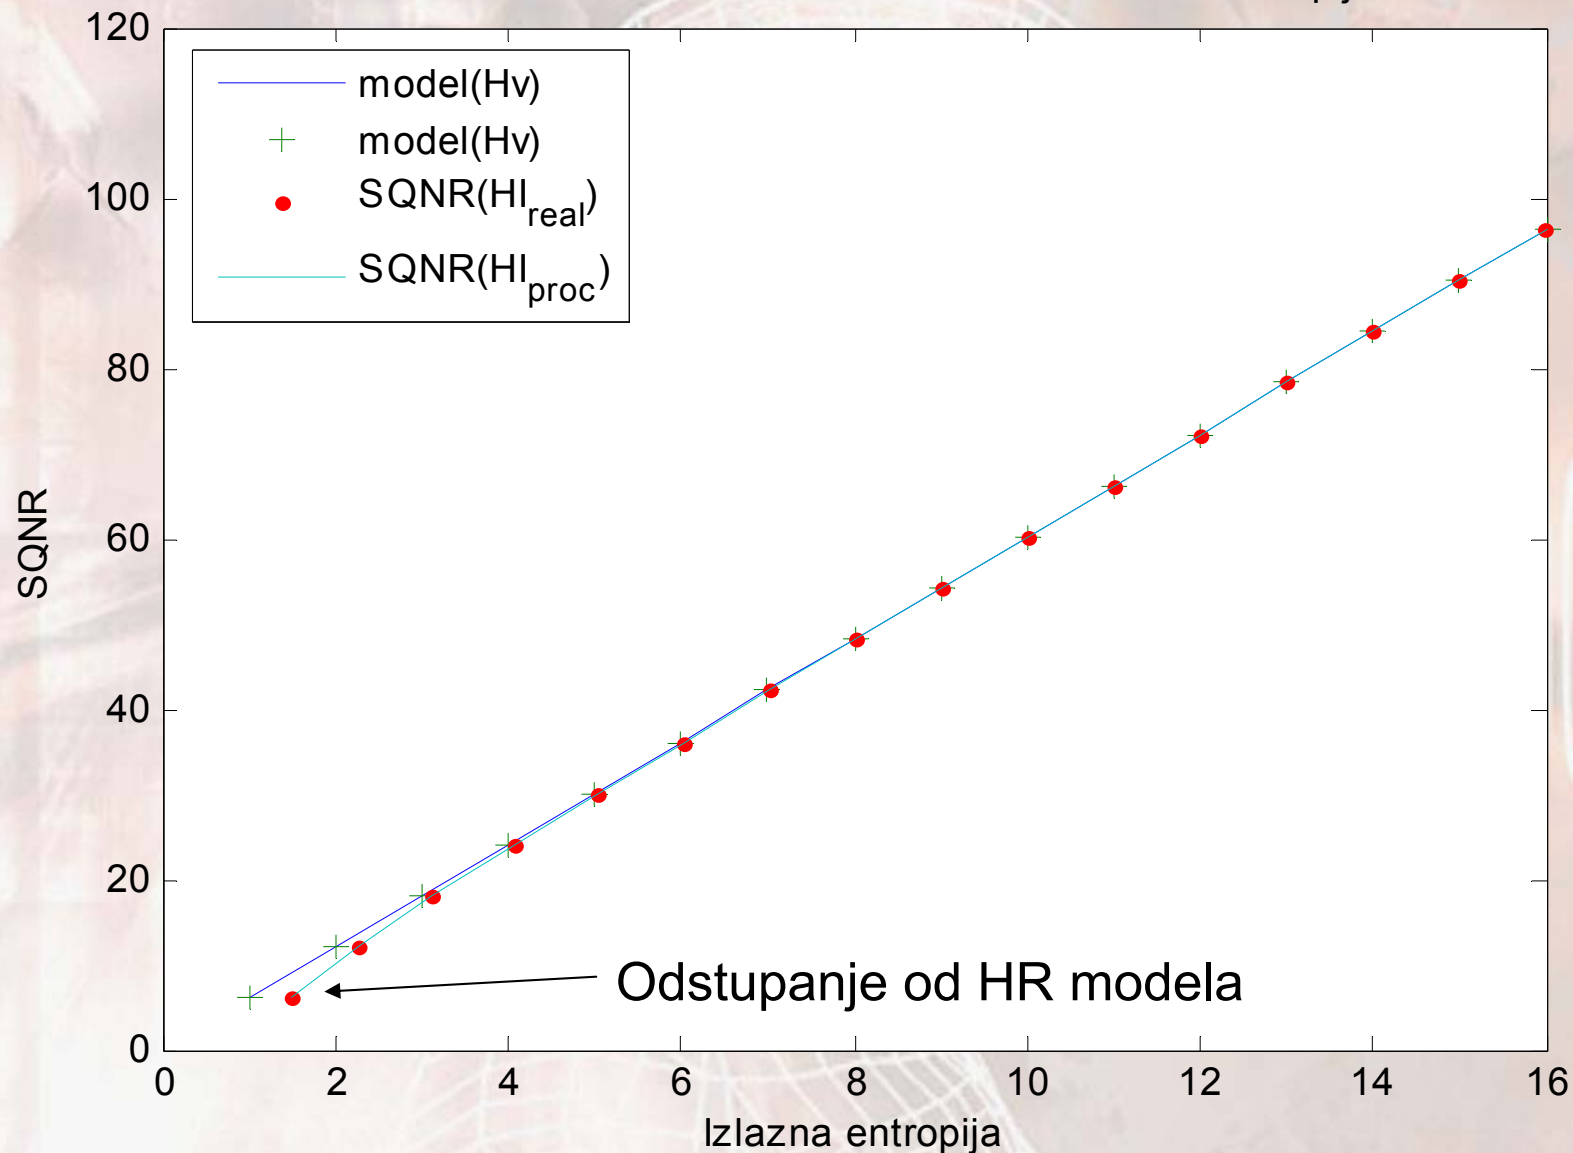
Stvarni i očekivani SQNR za stvarnu i očekivanu entropiju





3. Trokut – R-D krivulje $H(I)=1..16$

Stvarni i očekivani SQNR za stvarnu i očekivanu entropiju





Što smo naučili

- Teorija kvantizacije visokog podatkovnog toka
- temeljna ideja HR teorije
- odnos entropije i distorzije ECSQ kvantizatora
- diferencijalna entropija
- odnos signal/kvantizacijski šum kao funkcija entropije
- određivanje koraka kvantizatora
- određivanje entropije za zadanu kvalitetu
- primjer procesa uniformne gustoće vjerojatnosti
- primjer slučajnog procesa normalne gustoće vjerojatnosti
- gornja ograda entropije
- primjer HR analize u Matlabu